数据挖掘作业二

关联规则挖掘

姓名: CHANTHAMATH DETHSOMSAY 学号: 3820181029

一、问题描述

本次作业中,将对 Wine Reviews 数据集进关联规则挖掘。

- 1. 对数据集进行处理,转换成适合关联规则挖掘的形式
- 2. 找出频繁项集
- 3. 导出关联规则,计算其支持度和置信度
- 4. 对规则进行评价

二、关联规则挖掘过程

1. 对数据进行处理

获取 Wine Review 数据集的所有属性信息。分析数据集 Unamed 属性是索引, description 是属性描述,因此没有必要可以删除

```
# 删除Unnamed: 0和description
winedata = winedata.copy().drop(columns=['Unnamed: 0','description'])
winedata.info()
np.array(winedata.head())
```

在数据集中可以发现 points 和 price 是连续型数据,因此需要对这两个连续特征作离散化处理

```
# 处理points
bin = [0,75,80,85,90,95,100]
winedata['points'] = pd.cut(winedata['points'],bin)
winedata['points'] = winedata['points'].astype('str')
# 处理price
bin = [0,20,30,40,50,60,2100]
winedata['price'] = pd.cut(winedata['price'],bin)
winedata['price'] = winedata['price'].astype('str')
```

2. 找出频繁项集

采用 Aprior 算法构建频繁项集。Aprior 算法首先会生成所有单个属性名、属性值的项集列表,然后扫描全部数据集来查看哪些项集满足最小支持度要求,其中不满足最小支持度的集合会被去掉,对剩下的集合进行组合

```
def aprioriGen( Lk, k ):
   retList = []
   lenLk = len( Lk )
    for i in range( lenLk ):
       for j in range( i + 1, lenLk ):
    L1 = list( Lk[ i ] )[ : k - 2 ];
           L2 = list( Lk[ j ] )[ : k - 2 ];
           L1.sort(); L2.sort()
           if L1==L2:
                retList.append( Lk[ i ] | Lk[ j ] )
   return retList
def apriori( dataSet, minSupport = 0.5 ):
   C1 = createC1( dataSet ) # 构建初始候选项集C1
   D =list( map( set, dataSet )) # 将dataSet集合化
   L1, suppData = scanD( D, C1, minSupport )
                                               # 构建初始的频繁项集,即所有项集只有一个元素
   L = [L1]
   k = 2
   while ( len( L[k-2] ) > 0 ):
       Ck = aprioriGen(L[k-2], k)
       Lk, supK = scanD( D, Ck, minSupport )
       suppData.update( supK )
       L.append( Lk )
       k += 1
   return L, suppData
```

3. 结果

频繁项集输出结果:

关联规则输出结果: